

Bộ Giáo Dục & Đào Tạo
Trường Đại Học Công Nghệ TP.HCM-HUTECH



Môn học: **KHAI THÁC THÔNG TIN**

Mã đề tài: **07**

Tên đề tài: **Tìm hiểu về Apache Spark, OrientDB & áp dụng trong bài toán TF-IDF và PageRank**

1. Nội dung thực hiện

Nội dung của đề tài gồm các yêu cầu sau:

- Học viên tìm hiểu về Apache Spark, về lưu trữ dữ liệu phân tán trên Apache Hadoop – HDFS và lập trình với MapReduce.
- Học viên tìm hiểu cơ sở dữ liệu đồ thị OrientDB. OrientDB sẽ được dùng để lưu trữ các liên kết giữa các websites được thu thập.
- Học viên thực hiện thu thập dữ liệu các websites (đủ lớn tầm > 200-500 websites/webpages) cùng với các liên kết giữa chúng (lưu ý nên chọn tập các websites có liên kết với nhau để thực nghiệm cho thuật toán PageRank). Trong đó dữ liệu sẽ được chia ra để lưu trữ như sau:
 - Dữ liệu văn bản (text) thì lưu vào HDFS.
 - Dữ liệu các quan hệ giữa các websites thì lưu vào
- **Xây dựng một Spark cluster với 2-3 nodes** để thử nghiệm (có thể sử dụng máy ảo để xây dựng) – có cài đặt Apache Hadoop – HDFS và OrientDB để lưu trữ dữ liệu.
- **Thực nghiệm 01:** thực nghiệm tính **TF-IDF** cho các tài liệu được thu thập dựa trên Apache Spark (học viên có thể dùng thư viện **MLlib** hoặc tự lập trình).
- **Thực nghiệm 02:** thực nghiệm tính trọng số **PageRank** của các websites (học viên có thể dùng thư viện **GraphX** hoặc tự lập trình) dựa trên dữ liệu các quan hệ được lấy từ OrientDB.

2. Sản phẩm yêu cầu

Đề tài yêu cầu các sản phẩm sau:

- **Thuyết minh đề tài:** nộp dạng bài tiểu luận từ **20-25 trang**. Học viên nộp bài dưới cả 02 hình thức, gồm [**Bản mềm**]: Nộp trên hệ thống hỗ trợ học tập E-learning HUTECH (<http://e-graduate.hutech.edu.vn/portal>) và [**Bản cứng** – 2

bản]: Nộp cho Giảng viên phụ trách học phần. Nội dung trình bày trong bài thuyết minh:

- Lý thuyết nền tảng.
- Cách tiếp cận và các bước xây dựng hệ thống Spark Cluster.
- Minh họa về cài đặt các thực nghiệm 1 và 2.
- Minh họa & demo về các thực nghiệm.
- **Thuyết trình trước lớp:** có slides – thời gian thuyết trình từ 30-45 phút.
- Demo về thực nghiệm 1 & 2.

3. Hướng dẫn

- Thu thập dữ liệu các tài liệu/văn bản để thử nghiệm – tầm > 200-500 tài liệu (có thể thu thập từ các website tin tức, mạng xã hội, v.v.).
- Apache Spark và OrientDB (phiên bản community) có thể tải miễn phí tại:
 - <https://spark.apache.org/>
 - <https://orientdb.org/>
- Đối với Apache Spark – học viên có thể lựa chọn ngôn ngữ lập trình Java, Scala hoặc Python để tiến hành các thực nghiệm.
- Khuyến nghị nên cài đặt Apache Spark và OrientDB trên các nền tảng Linux để tránh các lỗi trên môi trường Windows.
- Để kết nối giữa Apache Spark và OrientDB – có thể sử dụng Spark Connector - <https://orientdb.org/integration/spark-connector>.

4. Tài liệu tham khảo

Học viên có thể tham khảo bất cứ nguồn tài liệu và mã nguồn phần mềm nào có thể lấy được từ Internet. Ngoài ra học viên có thể tham khảo thêm một số dự án mẫu dưới đây:

- <https://www.vultr.com/docs/install-apache-spark-on-ubuntu-20-04/>
- <https://computingforgeeks.com/install-and-configure-orientdb-on-ubuntu/>
- <https://orientdb.com/docs/2.2.x/Tutorial-Installation.html>
- <https://orientdb.org/integration/spark-connector>
- <https://spark.apache.org/docs/latest/mllib-feature-extraction.html>
- <https://spark.apache.org/docs/latest/graphx-programming-guide.html#pagerank>