



HUTECH

Đại học Công nghệ Tp.HCM

KHAI THÁC THÔNG TIN


**Tìm hiểu về Apache Spark, OrientDB
và áp dụng bài toán TF-IDF, Pagerank**

Giảng viên hướng dẫn : TS. Phạm Thế Anh Phú

Danh sách thành viên nhóm

- 01** Nguyễn Đông Hồ - 2441861016
- 02** Nguyễn Minh Chiến - 2441861007
- 03** Hà Anh Dũng - 2440861003
- 04** Nguyễn Minh Trung Nghĩa - 2441861021
- 05** Nguyễn Ngọc Đình - 2440861001
- 06** Phạm Huỳnh Cao Minh - 2441861016

Quy trình thực nghiệm



NỘI DUNG THUYẾT TRÌNH

- 01** Giới thiệu về Apache Spark và Hadoop
- 02** Giới thiệu về OrientDB
- 03** Thuật toán TF-IDF và Pagerank
- 04** Kết quả thực nghiệm và hướng phát triển


01

Giới thiệu về Apache Spark và Hadoop

Sơ lược về SPARK và công dụng

- Là hệ thống xử lý phân tán nguồn mở, được sử dụng cho các khối lượng công việc xử lý dữ liệu lớn.
- Sử dụng khả năng ghi vào bộ nhớ đệm, thực thi truy vấn tối ưu hóa.
- Tính toán trên bộ nhớ trong hoặc Ram, xử lý dữ liệu thời gian thực.
- Gồm 5 thành phần chính: Spark Core, Spark SQL, Spark Streaming, MLlib và GraphX.
- Hỗ trợ các ngôn ngữ: Java, Scala, Python và R.

Mô hình xử lý của Spark




Sơ lược về Hadoop và công dụng


- Là hệ thống lưu trữ phân tán trên phần cứng thông thường để lưu trữ các tệp dữ liệu kích thước lớn trên nhiều nút máy tính.
- Cho phép tạo nhóm nhiều máy tính để phân tích các bộ dữ liệu lớn đồng thời.
- Gồm 4 module chính: HDFS, YARN, Map Reduce, Hadoop Common.

Thành phần cấu trúc của Hadoop Distributed File System

HDFS architecture



Cách hoạt động của Map Reduce




02

Giới thiệu về OrientDB

Volume of data/information created, captured, copied, and consumed worldwide from 2010 to 2020, with forecasts from 2021 to 2025

(in zettabytes)



[Additional Information](#)

© Statista 2024

[Show source](#)

DOWNLOAD



PDF



XLS



PNG



PPT


Supplementary notes

* The data was taken from various publications released over several years: Forecast for the years 2018 and 2019 as of 2018; Forecast for 2020 as of May 2021; Forecast for 2021 to 2025 as of March 2021 based on figure for 2020 provided by the source. Figures were rounded to provide a better understanding of the statistic.

The figures from 2021 to 2025 were calculated by Statista based on the 2020 forecast figure and the five-year compound annual growth rate (CAGR) of 23 percent provided by the source. The figures prior to 2020 are based on IDC's forecast from late 2018.

Citation formats

[View options](#)



RethinkDB.



HAZELCAST
SOFTWARE



HYPERTABLE[™]

Khái niệm OrientDB


- Là hệ thống quản lý cơ sở dữ liệu NoSQL được viết bằng ngôn ngữ Java.
- Theo hướng đa mô hình, đa dạng loại cơ sở dữ liệu và hướng đối tượng.
- Cú pháp truy vấn tương tự SQL nhưng có thêm cú pháp và chức năng riêng biệt để làm việc với nhiều loại mô hình dữ liệu.
- Bao gồm 2 phiên bản Community Edition và Enterprise Edition.

Công dụng chính

- Xây dựng dữ liệu trên các mô hình: đồ thị, tài liệu, khóa-giá trị, đối tượng.
- Mở rộng và phân tán dữ liệu.
- Quản lý các quan hệ phức tạp cho các nhu cầu sử dụng dữ liệu khác nhau.

OrientDB Graph

SELECT FROM Website WHERE id = “4785199”





Follow

Luca Garulli

@lgarulli

Founder, Investor, Developer. Invented the Multi-Model Database concept, created #OrientDB Open Source DBMS (bought by @SAP), now @Arcade_DB

📍 Miami, Florida 🔗 arcadedata.com 📅 Joined September 2009

03

Thuật toán TF-IDF và Pagerank

TF-IDF: Dùng để cải thiện hiệu suất tìm kiếm và truy xuất thông tin

TF (Temp Frequency): tần suất xuất hiện của từ (x) trong tài liệu

$$TF(ij) = \frac{F_{ij}}{\max(F_{ij})}$$

F_{ij} : tần số xuất hiện của từ (i) trong tài liệu

$\max(F_{ij})$: tổng số từ xuất hiện nhiều nhất trong tài liệu

TF-IDF: Dùng để cải thiện hiệu suất tìm kiếm và truy xuất thông tin

IDF (Inverse Document Frequency): tần suất ngược của từ trong tập hợp tài liệu

$$IDF(i) = \log_2 \left(\frac{n}{DF(i)} \right)$$

N: tổng số tài liệu

DF(i): tổng số tài liệu có chứa từ khóa (i)

TF-IDF: Dùng để cải thiện hiệu suất tìm kiếm và truy xuất thông tin

TF (Temp Frequency): tần suất xuất hiện của từ (x) trong tài liệu

IDF (Inverse Document Frequency): tần suất ngược của từ trong tập hợp tài liệu

$$TF\text{-}IDF_{ij} = TF_{ij} \times IDF_i$$

Pagerank: Dùng để đánh giá mức độ tin cậy của một Website / tài liệu

$$PR(A) = (1-d) + \left(+\frac{PR(T1)}{C(T1)} + \frac{PR(T2)}{C(T2)} + \dots + \frac{PR(Tn)}{C(Tn)} \right)$$

PR(A): Pagerank của trang AA

d: hệ số giảm dần, thường là 0.85

PR(Tn): Pagerank của các trang Tn liên kết đến trang AA

C(Tn): số lượng liên kết outbound từ các Tn

04

Thực nghiệm và hướng phát triển

Hướng phát triển

- Mở rộng dữ liệu dataset của ứng dụng.
- Có khả năng thu thập được dữ liệu các trang web có độ phức tạp cao.
- Tăng tốc độ và hiệu suất bằng đa luồng hoặc phân tán hoá quá trình xử lý.
- Tích hợp với Spark Connect trong việc xử lý dữ liệu lớn bằng thuật toán Pagerank.
- Phát triển giao diện người dùng.

**Trân trọng cảm ơn thầy
và các bạn đã chú ý lắng nghe !**

Q&A



IRS-GROUP-7

Công cụ tìm kiếm

CÁCH ĐẶT CÂU HỎI CHO NHÓM 7 VÌ NHÓM THUYẾT TRÌNH XUẤT SẮC QUÁ KHÔNG BIẾT HỎI GÌ ĐÂY

